

Oefening en uitgewerkte oplossing

Simulatie & machine learning

Vier delen om te simuleren en uit data te leren: de Monte Carlo-fout, de bootstrap en VaR, datavoorbereiding voor ML, en het evalueren van een classifier. Werk elk deel uit voordat u de oplossing leest.

Deel A · De Monte Carlo-fout

OPGAVE

Een Monte Carlo-simulatie met $b = 8.000$ replicaties geeft een standaardfout van 0,60. (a) Hoeveel replicaties om de standaardfout tot 0,15 te brengen? (b) Waarom verbetert de precisie zo traag?

OPLOSSING

- (a) We willen de fout door 4 delen ($0,60 \rightarrow 0,15$). Aangezien $s.e. \propto 1/\sqrt{b}$, moeten we b vermenigvuldigen met $4^2 = 16$, dus **128.000** replicaties.
- (b) De CLT geeft $s.e. = \sigma/\sqrt{b}$: de fout daalt als $1/\sqrt{b}$, niet $1/b$. De fout halveren vereist dus $4\times$ meer replicaties, en een factor 10 aan precisie vergt $100\times$. Dat is de wortelkost, essentieel om een simulatie te dimensioneren.

Deel B · Bootstrap en VaR

OPGAVE

Een risk manager schat een jaarlijkse S&P 500-VaR via bootstrap. (a) Trekken met of zonder teruglegging, en waarom zijn herhalingen geen fout? (b) De rendementen vertonen volatility clustering. iid bootstrap of CBB, en welke blokgrootte? (c) Welke fundamentele grens belet de bootstrap een nieuwe crisis te voorspellen?

OPLOSSING

- (a) **Met teruglegging**: dezelfde waarneming kan meermaals terugkomen, wat normaal is (minstens één herhaling is bijna zeker zodra je veel steekproeven trekt). Dit trekken-met-teruglegging laat toe veel steekproeven te bouwen uit één dataset.
- (b) Een **CBB** (circular block bootstrap), want de data zijn afhankelijk: het trekt blokken van q opeenvolgende waarnemingen en bewaart de volatiliteitsclusters. Blokgrootte $q \approx \sqrt{n}$. Een iid bootstrap zou de clusters breken en de extreme VaR onderschatten.
- (c) De bootstrap herbemonstert de historie: ze kan **nooit een verlies genereren erger dan het grootste al waargenomen** (Black Swan). Ze mengt ook alle regimes, wat haar misleidend maakt wanneer de markt in een abnormale toestand komt. Een goed simulatiemodel kan wel extrapoleren voorbij de historie.

Deel C · Data voorbereiden voor ML

OPGAVE

(a) Een feature heeft een gemiddelde van 40 en een standaardafwijking van 5. Standaardiseer de waarneming $x = 52$. (b) Wanneer verkiest men standardization boven min-max-normalization? (c) Herschalen we ook het target?

OPLOSSING

- (a) $\tilde{x} = (x - \mu)/\sigma = (52 - 40)/5 = 12/5 = \mathbf{2,4}$: de waarneming ligt 2,4 standaardafwijkingen boven het gemiddelde. Na standardization heeft de feature gemiddelde 0 en variantie 1.
- (b) Standardization is verkozen **bij uitschieters**: min-max-normalization (delen door $\max - \min$) zou dan de meeste waarnemingen in een smalle reeks persen, niet representatief voor hun echte spreiding.
- (c) **Nee**: we herschalen enkel de **features** (inputs), nooit het **target** (de te voorspellen variabele). Rescaling zet features op dezelfde schaal zodat afstanden en straffen ze eerlijk vergelijken.

Deel D · Een classifier evalueren

OPGAVE

Een fraudedetectiemodel geeft, op 500 transacties: TP = 180, FN = 60, FP = 40, TN = 220. (a) Bereken accuracy, precision en recall. (b) Is een AUC van 0,5 een “gemiddelde” score? (c) Een niet-gedetecteerde fraude is zeer duur: hoe de drempel Z aanpassen, en ten koste van wat?

OPLOSSING

1. (a) Accuracy = $(180+220)/500 = \mathbf{80,0\%}$. Precision = $TP/(TP+FP) = 180/220 = \mathbf{81,8\%}$. Recall = $TP/(TP+FN) = 180/240 = \mathbf{75,0\%}$.
2. (b) **Nee**: een AUC van 0,5 is de toevalsdiagonaal, dus **geen voorspelkracht**. AUC = 1 is een perfecte classifier; een AUC onder 0,5 doet slechter dan toeval.
3. (c) Een valse negatieve (niet-gedetecteerde fraude) is duur: we **verlagen de drempel Z** (bv. naar 0,2 in plaats van 0,5) om “fraude” te voorspellen zodra zelfs een klein risico bestaat. Dit verhoogt de recall (minder gemiste fraudes), ten koste van **lagere precision** (meer valse alarmen): dat is de afweging die de ROC-curve tekent.

Onthoud: de Monte Carlo-fout daalt als $1/\sqrt{b}$ ($\div 2 \Rightarrow \times 4$ replicaties); de bootstrap trekt met teruglegging en creëert nooit een nieuw verlies (CBB bij afhankelijkheid, $\sqrt{n}$ -blokken); herschaal de features (niet het target), standardization bij uitschieters; en een classifier wordt beoordeeld via precision, recall en AUC (0,5 = geen voorspelkracht), waarbij de drempel Z valse positieven tegen valse negatieven afweegt.