

Exercice et corrigé

Régression linéaire

Quatre parties pour maîtriser la régression OLS de bout en bout : estimation des paramètres, inférence sur la pente, diagnostic d'un modèle (variable omise, multicollinéarité), et lecture de l'hétéroscédasticité. Traitez chaque partie avant de lire la solution.

Partie A · Estimer une droite OLS

ÉNONCÉ

On régresse le rendement d'un secteur (Y) sur celui du marché (X) sur 20 ans. On mesure une covariance $\sigma_{XY} \approx 512,3$, une variance $\sigma_X^2 = 337,3$, une moyenne $\bar{y} = 15,4\%$ et $\bar{x} = 7,77\%$. (a) Calculez la pente β . (b) Calculez l'intercept α et interprétez-le.

SOLUTION

- (a) $\beta = \sigma_{XY} / \sigma_X^2 = 512,3 / 337,3 = \mathbf{1,52}$. Quand le marché gagne 1 %, le secteur gagne en moyenne 1,52 %. C'est un $\beta > 1$, donc un secteur plus volatil que le marché.
- (b) $\alpha = \bar{y} - \beta \bar{x} = 15,4 - 1,52 \times 7,77 = 15,4 - 11,81 = \mathbf{3,60\%}$. C'est le rendement moyen du secteur lorsque le marché est à zéro (le rendement « anormal » au sens du CAPM). Rappel : $\beta = \rho \cdot \sigma_Y / \sigma_X$, donc $\beta = 0$ si et seulement si la corrélation est nulle.

Partie B · Inférence sur la pente

ÉNONCÉ

La même régression donne $\beta = 1,52$ avec une erreur-type $s.e.(\beta) = 0,40$. (a) Calculez la t-statistic pour $H_0 : \beta = 0$ et concluez à 5 %. (b) Donnez le CI 95 %. (c) Le R^2 vaut 0,44 : que mesure-t-il ?

SOLUTION

- (a) $t = \beta / s.e.(\beta) = 1,52 / 0,40 = \mathbf{3,80}$. Comme $3,80 > 1,96$, on **rejette H_0** à 5 % : la pente est significativement non nulle.
- (b) $CI\ 95\% = \beta \pm 1,96 \times s.e. = 1,52 \pm 1,96 \times 0,40 = 1,52 \pm 0,784 = \mathbf{[0,74 ; 2,30]}$. Il ne contient pas 0 : même conclusion que le test, deuxième lecture. La troisième (p-value $\approx 0,01\% < 5\%$) confirme encore.
- (c) Le $R^2 = 0,44$ est la part de la variance de Y expliquée par X . En régression simple, $R^2 = \rho^2$: ici la corrélation vaut $\sqrt{0,44} \approx 0,66$. Le R^2 est symétrique (régresser Y sur X ou X sur Y donne le même), contrairement à la pente.

Partie C · Variable omise et multicollinéarité

ÉNONCÉ

(a) Le vrai modèle est $Y = 2 + 1,2 X_1 - 2,1 X_2 + \varepsilon$, avec $\delta = \text{Cov}(X_1, X_2) / V(X_1) = 0,60$. On omet X_2 . Vers quelle valeur converge le coefficient estimé de X_1 ? (b) Dans un autre modèle, la corrélation entre deux régresseurs vaut $\rho = 0,96$. Calculez le VIF et concluez.

SOLUTION

- (a) Biais de variable omise : $\beta_1 \rightarrow \beta_1 + \beta_2 \delta = 1,2 + (-2,1) \times 0,60 = 1,2 - 1,26 = \mathbf{-0,06}$. Le biais est si fort que le **signe s'inverse** : l'effet vrai (+1,2) apparaît négatif. Deux conditions étaient réunies : X_2 compte ($\beta_2 \neq 0$) et X_1, X_2 sont corrélés ($\delta \neq 0$).
- (b) À deux variables, $R_j^2 = \rho^2 = 0,96^2 = 0,9216$. $VIF = 1 / (1 - R_j^2) = 1 / 0,0784 \approx \mathbf{12,8}$. Comme $12,8 > 10$, la multicollinéarité est excessive. Ce n'est pas une faute technique (aucune hypothèse violée), juste un problème de lisibilité : le F peut rester significatif alors que les t individuels sont faibles.

Partie D · Hétéroscédasticité et robustesse

ÉNONCÉ

Un analyste teste le facteur *size* d'un portefeuille. Sous homoscélasticité, le t vaut $-3,2$ (significatif). Avec des erreurs-types robustes, le t tombe à $-1,3$. (a) Qu'est-ce qui a changé, et pourquoi ? (b) Les coefficients sont-ils biaisés ? (c) Quelle conclusion retenir ?

SOLUTION

1. (a) Les données sont **hétéroscédastiques** (variance du choc dépendant de X , détectable par le test de White). Les s.e. usuels sont alors trop petits, ce qui gonfle artificiellement la t -stat ; les s.e. robustes (plus grands) corrigent cela et la t -stat retombe.
2. (b) **Non**. L'hétéroscédasticité laisse les coefficients non biaisés et consistants : seuls les erreurs-types sont faux. C'est le piège classique — répondre « estimateurs biaisés » est incorrect.
3. (c) Avec $-1,3$, en valeur absolue sous 1,96, le facteur **n'est plus significatif**. On retient la conclusion robuste. Si les cinq hypothèses tiennent, OLS est BLUE ; avec en plus la normalité des erreurs, il devient BUE.

À retenir : $\beta = \text{cov/var} = \rho \cdot \sigma_y / \sigma_x$ (donc $\beta = 0 \iff \rho = 0$) ; on teste par $t = \beta / \text{s.e.}$, avec l'équivalence $|t| > 1,96 \iff p < 5 \% \iff 0 \notin \text{CI}$; omettre une variable corrélée biaise les coefficients ; le VIF > 10 signale la multicolinéarité ; et l'hétéroscédasticité fausse les s.e. mais jamais les coefficients.